

Academia de Studii Economice
FACULTATEA DE CIBERNETICĂ, STATISTICĂ ȘI INFORMATICĂ ECONOMICĂ
DEPARTAMENTUL DE INFORMATICĂ ECONOMICĂ



Proiect Pachete Software
Analiza Macro și Micro a Performanțelor Școlare: O Abordare
Interactivă Bazată pe Date

Profesor coordonator,

Asistent univ. Niculae
Andreea-Mihaela

Studenți,

Cazan Alexia-Ioana
Călugăru Mircea-Costin

Cuprins

- Introducere
- Definirea problemei
- Programare Python - Streamlit
- Sursa datelor și contextul analizei
- Funcționalități Python / Streamlit
- Programare SAS
- Funcționalități SAS
- Interpretarea economică
- Concluzii finale - Recomandări

Introducere

Proiectul analizează performanțele școlare ale studenților printr-o abordare bazată pe date, combinând procesarea statistică în SAS cu o interfață interactivă dezvoltată în Python / Streamlit. Scopul general este transformarea datelor educaționale brute în informații utile pentru luarea deciziilor manageriale și educaționale.

Documentația este organizată pe funcționalități, conform cerințelor proiectului. Pentru fiecare funcționalitate sunt prezentate obiectivul economic, informațiile necesare pentru rezolvare, metodele de calcul sau algoritmi utilizați, rezultatele și interpretarea economică a acestora.

Definirea problemei

Educația reprezintă catalizatorul fundamental pentru dezvoltarea umană și progresul socio-economic al oricărei societăți moderne. Într-o economie globală tot mai dependentă de cunoaștere și inovație, calitatea actului educațional și performanța academică a elevilor dictează direct gradul de competitivitate și bunăstare al viitoarelor generații. Cu toate acestea, în ciuda importanței sale recunoscute, sistemele educaționale tradiționale se confruntă adesea cu o dificultate majoră în a înțelege pe deplin mecanismele care generează succesul sau eșecul școlar la nivel individual.

În prezent, instituțiile de învățământ colectează zilnic un volum impresionant de date (note, prezențe, date demografice). Problema principală nu este lipsa informației, ci sub-exploatarea acesteia. De cele mai multe ori, aceste date rămân blocate în cataloage sau în tabele statice, fiind utilizate strict pentru raportări administrative și evaluări sumative. Notele sunt privite ca un rezultat absolut, fără a se investiga ecosistemul complex în care se află elevul. Astfel, se pierde oportunitatea de a identifica tipare ascunse și de a lua decizii proactive. Când un elev începe să aibă rezultate slabe, intervenția școlii este adesea reactivă și târzie, tratând efectul (nota mică) și nu cauza de bază (lipsa de implicare, oboseala generată de un job part-time sau absenteismul cronic).

Problema centrală pe care o abordează acest proiect este absența unui mecanism analitic integrat care să coreleze performanța școlară cu factorii externi și de comportament ai elevilor. Fără o mapare clară a modului în care efortul individual (orele de studiu), mediul socio-economic (necesitatea unui job) și nivelul de motivație (aspirațiile de carieră) influențează direct notele la materii specifice, strategiile de îmbunătățire a educației rămân doar la nivel teoretic.

Pentru a răspunde acestei probleme, lucrarea de față propune tranziția de la simpla stocare a datelor la diagnoza educațională interactivă. Prin combinarea rigoarei statistice oferite de tehnologia SAS cu flexibilitatea și accesibilitatea interfețelor dezvoltate în Python (Streamlit), proiectul își propune să transforme datele educaționale brute într-un instrument de decizie vizual. Această abordare permite identificarea profilului elevului cu risc de abandon sau eșec școlar și oferă cadrelor didactice și conducerii posibilitatea de a implementa intervenții personalizate, bazate pe dovezi clare, nu pe intuiție.

Programare Python - Streamlit

Streamlit reprezintă componenta de interfață interactivă a proiectului. Dacă SAS este folosit pentru procesare statistică și validare analitică, partea Streamlit transformă datele și rezultatele în pagini ușor de explorat de către utilizator. Aplicația permite încărcarea dataset-ului, vizualizarea structurii datelor, construirea unei variabile țintă, analiza exploratorie, preprocesarea datelor și rularea unor modele predictive de regresie.

Prin Streamlit, analiza devine accesibilă pentru un utilizator non-tehnic, de exemplu un manager educațional sau o persoană responsabilă de monitorizarea performanței studenților. Utilizatorul poate schimba filtre, poate selecta variabile, poate compara grupuri și poate observa rapid relațiile dintre absențe, studiu individual, activități extracurriculare și performanța academică.

- Interactivitate: aplicația folosește filtre, selectbox-uri, slider-e, checkbox-uri, radio button-uri și butoane pentru a permite utilizatorului să aleagă scenariul de analiză.
- Vizualizare: graficele sunt construite cu Plotly, sub formă de histogramme, box plot-uri, violin plot-uri, bar chart-uri, treemap-uri, matrice de corelație și grafice real vs. prezis.
- Modelare predictivă: aplicația include modele de regresie precum Linear Regression, KNN Regressor și Random Forest Regressor, evaluate prin indicatori precum R^2 , RMSE și MAE.
- Persistența rezultatelor: aplicația folosește `st.session_state` pentru a păstra dataset-ul pregătit și rezultatele obținute între pașii de preprocesare și modelare.

Sursa datelor și contextul analizei

Sursa datelor: Platforma Kaggle - Student Scores Dataset. Fișierul folosit în aplicație este citit din calea `data/student-scores.csv`.

Context: setul de date conține informații despre studenți, comportamentul lor educațional, aspirațiile profesionale și scorurile obținute la mai multe discipline. Scopul analizei este identificarea factorilor care pot influența performanța academică și construirea unui model care să estimeze scorul mediu al unui student.

Indicatorul central construit în aplicație este `average_score`, calculat ca media scorurilor obținute la cele șapte discipline: matematică, istorie, fizică, chimie, biologie, engleză și geografie.

Variabilă	Descriere
id	Identificator unic pentru fiecare student.
first_name	Prenumele studentului.
last_name	Numele de familie al studentului.
email	Adresa de email asociată studentului.
gender	Genul studentului.
part_time_job	Indică dacă studentul are un job part-time.
absence_days	Numărul de zile de absență.
extracurricular_activities	Indică participarea la activități extracurriculare.
weekly_self_study_hours	Numărul de ore de studiu individual pe săptămână.
career_aspiration	Domeniul sau cariera vizată de student.
math_score	Scorul obținut la matematică.
history_score	Scorul obținut la istorie.
physics_score	Scorul obținut la fizică.
chemistry_score	Scorul obținut la chimie.
biology_score	Scorul obținut la biologie.
english_score	Scorul obținut la limba engleză.

geography_score	Scorul obținut la geografie.
average_score	Variabilă derivată în aplicație, calculată ca media scorurilor pe discipline.

Funcționalitatea 1 - Pagina principală și filtrarea generală a dataset-ului

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic al paginii principale este oferirea unei imagini rapide asupra dataset-ului și a scopului proiectului. Utilizatorul poate înțelege ce tip de date sunt analizate și ce componente include aplicația.

Această funcționalitate sprijină decizia managerială prin filtrarea rapidă a studenților în funcție de gen, aspirație profesională și nivelul de studiu individual. Astfel, utilizatorul poate observa segmentul relevant înainte de a intra în analize mai detaliate.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Variabilă / element	Rol în funcționalitate
gender	Variabilă folosită în filtrul din sidebar pentru selectarea genurilor analizate.
career_aspiration	Variabilă folosită pentru filtrarea studenților după cariera dorită.
weekly_self_study_hours	Variabilă folosită pentru filtrarea intervalului de ore de studiu individual.
absence_days	Variabilă folosită pentru afișarea mediei absențelor în segmentul filtrat.
număr de înregistrări	Indicator afișat pentru a vedea dimensiunea segmentului analizat.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Datele sunt încărcate cu funcția `pd.read_csv`, iar funcția de încărcare este memorată cu `st.cache_data` pentru a evita reîncărcarea inutilă a fișierului la fiecare interacțiune.

Filtrarea se face prin condiții aplicate pe dataframe: selecția genurilor, selecția aspirațiilor profesionale și intervalul de ore de studiu individual.

Indicatorii afișați pe pagina principală sunt calculați prin agregări simple: numărul de rânduri filtrate, media `weekly_self_study_hours` și media `absence_days`.

d) Prezentarea rezultatelor: capturi de ecran



Scopul proiectului

Analiza performanței studenților și identificarea factorilor care pot influența rezultatele academice.



Abordare

Combinarea analizei exploratorii, cu modele de Machine Learning într-o aplicație Streamlit interactivă.



Tehnologii

Pandas, Matplotlib, Plotly, scikit-learn și Streamlit pentru o aplicație interactivă multi-pagină.

 **Filtre dataset**

Gen

female x male x x v

Job part-time

Nu x Da x x v

Activități extracurriculare

Nu x Da x x v



e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Această pagină oferă o primă segmentare a datelor. Din perspectivă economică, instituția poate observa rapid dacă anumite categorii de studenți au un comportament educațional diferit.

Recomandare: filtrele pot fi folosite înaintea deciziilor de intervenție educațională, pentru a identifica grupuri care necesită sprijin, consiliere sau programe suplimentare de pregătire.

Funcționalitatea 2 - Date și statistici: înțelegerea structurii dataset-ului

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic este validarea și înțelegerea datelor înainte de orice analiză avansată. O decizie de business bazată pe date este corectă doar dacă datele sunt complete, coerente și corect interpretate.

Pagina Date și statistici permite explorarea rândurilor, tipurilor de variabile, valorilor lipsă și statisticilor descriptive, reducând riscul de interpretări greșite.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Variabilă / element	Rol în funcționalitate
toate variabilele inițiale	Sunt folosite pentru prezentarea structurii generale a dataset-ului.

variabile numerice	Sunt analizate prin statistici descriptive precum medie, minim, maxim și deviație standard.
variabile categoriale	Sunt analizate prin distribuții de frecvență.
valori lipsă	Sunt verificate pentru a decide dacă este necesară imputarea sau eliminarea unor observații.
loc și iloc	Sunt folosite pentru demonstrarea accesării datelor prin etichete și poziții.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Metoda loc permite selectarea datelor pe baza denumirilor de coloane sau a condițiilor logice, de exemplu studenții cu un anumit nivel al unei variabile.

Metoda iloc permite selectarea datelor pe baza pozițiilor numerice ale rândurilor și coloanelor.

Pentru valorile lipsă se calculează suma valorilor nule pe fiecare coloană și procentul corespunzător: număr valori lipsă / număr total rânduri * 100.

Statisticile descriptive sunt obținute cu metode pandas, iar distribuțiile sunt vizualizate prin grafice categoriale și numerice.

d) Prezentarea rezultatelor: capturi de ecran

Selectare condițională cu loc

Aici folosim **loc** pentru a selecta rândurile care respectă o condiție. Poți alege coloana numerică, operatorul, valoarea de comparație și coloanele care vor fi afișate.

Coloană pentru condiție

Operator

Valoare de comparație

Scor matematică

>=

87.00

Coloane afișate

ID

Gen

Zile de absență

Ore de studiu in...

Scor matematică

```
df.loc[df["math_score"] >= 87.0, ["id", "gender", "absence_days", "weekly_self_study_hours", "math_score"]].head(15)
```

Rezultat loc

id	gender	absence_days	weekly_self_study_hours	math_score
2	female	2	47	90
6	female	2	26	93
7	male	3	23	99
8	male	2	34	95
9	male	6	25	94
10	female	3	18	98
13	female	7	4	94
15	female	3	39	96
16	male	6	0	94
17	female	3	30	92

Primele rânduri Tipuri de variabile Valori lipsă

Câte rânduri vrei să afișezi?

10

id	first_name	last_name	email	gender	part_time_job	ab
1	Paul	Casey	paul.casey.1@gslingacademy.com	male	☐	
2	Danielle	Sandoval	danielle.sandoval.2@gslingacademy.com	female	☐	
3	Tina	Andrews	tina.andrews.3@gslingacademy.com	female	☐	
4	Tara	Clark	tara.clark.4@gslingacademy.com	female	☐	
5	Anthony	Campos	anthony.campos.5@gslingacademy.com	male	☐	
6	Kelly	Wade	kelly.wade.6@gslingacademy.com	female	☐	
7	Anthony	Smith	anthony.smith.7@gslingacademy.com	male	☐	
8	George	Short	george.short.8@gslingacademy.com	male	☒	
9	Stanley	Gutierrez	stanley.gutierrez.9@gslingacademy.com	male	☐	
10	Audrey	Simpson	audrey.simpson.10@gslingacademy.com	female	☐	

Pasul 4 - Distribuții ale variabilelor

Această secțiune permite vizualizarea distribuției variabilelor relevante. Pentru variabilele categoriale, folosim grafice de tip bar chart, iar pentru variabilele numerice folosim histogramă sau box plot.

Distribuții categoriale Distribuții numerice

Alege variabila categorială

Gen

Distribuția variabilei Gen



e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Această funcționalitate confirmă dacă dataset-ul poate fi folosit în continuare pentru analiză și modelare. Dacă există valori lipsă sau variabile cu tipuri necorespunzătoare, acestea trebuie tratate înainte de etapa de machine learning.

Recomandare: instituția trebuie să standardizeze colectarea datelor educaționale pentru a evita lipsa informațiilor critice precum absențele, orele de studiu sau scorurile pe discipline.

Funcționalitatea 3 - Feature Engineering: crearea variabilei `average_score`

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic este construirea unui indicator sintetic de performanță academică. În loc să analizăm separat fiecare notă, aplicația creează o singură variabilă țintă: `average_score`.

Această variabilă permite compararea studenților și construirea unui model predictiv mai simplu, orientat către performanța generală.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Variabilă / element	Rol în funcționalitate
<code>math_score</code>	Scor individual inclus în calculul mediei.
<code>history_score</code>	Scor individual inclus în calculul mediei.
<code>physics_score</code>	Scor individual inclus în calculul mediei.
<code>chemistry_score</code>	Scor individual inclus în calculul mediei.
<code>biology_score</code>	Scor individual inclus în calculul mediei.
<code>english_score</code>	Scor individual inclus în calculul mediei.
<code>geography_score</code>	Scor individual inclus în calculul mediei.
<code>average_score</code>	Rezultatul final al feature engineering-ului și viitorul target al modelului.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Formula utilizată este: $\text{average_score} = (\text{math_score} + \text{history_score} + \text{physics_score} + \text{chemistry_score} + \text{biology_score} + \text{english_score} + \text{geography_score}) / 7$.

În cod, variabila este calculată prin selectarea listei de coloane de scor și aplicarea metodei `mean(axis=1)`, adică media pe fiecare rând/student.

După calcul, aplicația afișează media, minimul și maximul variabilei `average_score`, apoi oferă o previzualizare a dataset-ului actualizat.

d) Prezentarea rezultatelor: capturi de ecran

✓ **Vezi codul folosit pentru crearea variabilei `average_score`**

```
score_columns = [  
    "math_score",  
    "history_score",  
    "physics_score",  
    "chemistry_score",  
    "biology_score",  
    "english_score",  
    "geography_score",  
]  
  
df["average_score"] = df[score_columns].mean(axis=1)
```

80.98

SCOR MEDIU GENERAL


59.14

SCOR MINIM

96.14

SCOR MAXIM

Distribuția variabilei average_score



e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Variabila average_score transformă performanța pe discipline într-un indicator ușor de interpretat la nivel managerial.

Recomandare: indicatorul poate fi folosit pentru monitorizarea performanței generale, dar analiza pe discipline trebuie păstrată separat pentru intervenții specifice, de exemplu sprijin la matematică sau fizică.

Funcționalitatea 4 - Analiza exploratorie a datelor

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic este identificarea relațiilor dintre variabilele existente și performanța academică. Analiza exploratorie ajută la observarea factorilor care pot avea valoare predictivă înainte de construirea modelului.

Pagina permite analiză agregată, comparații între grupuri și analiză de corelație, astfel încât utilizatorul să înțeleagă ce variabile sunt relevante pentru average_score.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Variabilă / element	Rol în funcționalitate
average_score	Indicator central analizat în comparațiile pe grupuri și în matricea de corelație.
gender	Variabilă categorială pentru gruparea studenților.
part_time_job	Variabilă pentru compararea studenților care lucrează part-time cu cei care nu lucrează.
extracurricular_activities	Variabilă pentru observarea diferențelor asociate implicării extracurriculare.
career_aspiration	Variabilă pentru analizarea performanței pe aspirații profesionale.
weekly_self_study_hours	Variabilă numerică pentru relația dintre studiu individual și performanță.
absence_days	Variabilă numerică pentru relația dintre absențe și performanță.
scorurile pe discipline	Pot fi incluse în corelații pentru analiză exploratorie, dar nu trebuie folosite ca predictori direcți ai average_score.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Analiza agregată grupează datele după o categorie și calculează indicatori precum media, minimul, maximul sau numărul de observații.

Comparația între grupuri folosește bar chart, box plot sau violin plot pentru a observa diferențele de average_score între categorii.

Analiza corelațiilor poate folosi metodele Pearson, Spearman sau Kendall Tau, în funcție de tipul relației urmărite. Matricea de corelație permite identificarea variabilelor asociate cu average_score.

Pearson măsoară asocierea liniară, Spearman măsoară relația monotonă pe ranguri, iar Kendall Tau este o măsură robustă bazată pe concordanța rangurilor.

d) Prezentarea rezultatelor: capturi de ecran

Pasul 1 - Analiză agregată pentru susținerea modelului

Această secțiune permite compararea unor indicatori prin grupare. Este utilă pentru a înțelege dacă anumite categorii de studenți au, în medie, scoruri mai mari, mai multe absențe sau mai multe ore de studiu. Aceste observații pot ghida alegerea variabilelor pentru Machine Learning.

Categoria analizată

Aspirație profesională

Indicator analizat

Scor mediu

Tip agregare

Medie

Alege tipul de vizualizare



Bar chart



Treemap

Pasul 2 - Comparația scorului mediu între grupuri

Această secțiune compară **average_score** între grupuri de studenți. Aici este inclusă și categoria de studiu, creată pe baza variabilei **weekly_self_study_hours**, împărțită în intervale de câte 10 ore. Această grupare ajută la observarea modului în care scorul mediu diferă în funcție de nivelul de studiu individual.

Grupează scorul mediu după

Gen

Tip grafic pentru comparație



Bar chart - medie



Box plot



Violin plot

Pasul 3 - Analiza interactivă a corelațiilor

Această secțiune calculează corelațiile dintre variabilele numerice. Pentru analiza orientată spre Machine Learning, este important să observăm ce variabile sunt asociate cu **average_score**. Poți alege metoda de corelație: **Pearson**, **Spearman** sau **Kendall Tau**.

Metoda de corelație

- ☒ Pearson
- ☐ Spearman
- ☐ Kendall Tau

Tip de vizualizare

Heatmap

☒ Include scorurile pe discipline

Alege variabilele pentru matricea de corelație


Zile de absență ×

Ore de studiu in... ×

Scor mediu ×



Matrice de corelație - metoda Pearson



e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Analiza exploratorie poate evidenția dacă absențele, studiul individual sau activitățile extracurriculare sunt asociate cu rezultate academice mai bune sau mai slabe.

Recomandare: variabilele cu asociere puternică față de average_score trebuie urmărite în rapoarte periodice, deoarece pot indica zone unde instituția poate interveni: reducerea absențelor, susținerea studiului individual sau încurajarea activităților extracurriculare.

Funcționalitatea 5 - Preprocesarea datelor pentru Machine Learning

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic este pregătirea unui dataset curat și adecvat pentru modelare predictivă. Calitatea modelului depinde direct de calitatea datelor introduse în algoritm.

Pagina de preprocesare elimină variabilele nepotrivite, identifică valori extreme, oferă preview pentru encoding și pentru scalare, apoi păstrează rezultatele în `st.session_state` pentru etapa de Machine Learning.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Variabilă / element	Rol în funcționalitate
id, first_name, last_name, email	Variabile de identificare eliminate deoarece nu au valoare predictivă și pot introduce probleme de confidențialitate.
career_aspiration	Eliminată în prima versiune deoarece are multe categorii și valori Unknown, putând crește complexitatea modelului.
scorurile individuale pe discipline	Eliminate deoarece sunt folosite pentru calcularea <code>average_score</code> și ar produce data leakage.
gender	Variabilă categorială pentru care se prezintă One-Hot Encoding.
weekly_self_study_hours	Predictor numeric analizat pentru outlieri și scalare.
absence_days	Predictor numeric folosit în model și scalare.
average_score	Targetul modelului; nu se scalează și nu se folosește ca predictor.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Eliminarea variabilelor se face prin `drop(columns=...)`. Motivul principal este păstrarea doar a predictorilor relevanți și evitarea data leakage-ului.

Detectarea outlierilor se face prin două metode. Metoda IQR folosește Q1, Q3 și intervalul intercuartilic: $IQR = Q3 - Q1$. Limitele sunt $Q1 - k \cdot IQR$ și $Q3 + k \cdot IQR$.


Metoda Z-score folosește formula $z = (x - \text{media}) / \text{deviația standard}$. Valorile pentru care $|z|$ depășește pragul selectat sunt marcate ca outlieri.

One-Hot Encoding transformă o variabilă categorială, precum gender, în coloane numerice dummy, astfel încât modelul să poată utiliza informația.

Scalarea numerică este prezentată prin `StandardScaler` și `MinMaxScaler`. `StandardScaler` transformă datele în funcție de medie și deviație standard, iar `MinMaxScaler` le aduce într-un interval standardizat, de obicei $[0, 1]$.

d) Prezentarea rezultatelor: capturi de ecran

Tabel cu variabilele eliminate



Variabilă eliminată	Motiv
id	Identificator tehnic; nu conține informație predictivă utilă.
first_name	Informație personală; nu este relevantă pentru predicția performanței.
last_name	Informație personală; nu este relevantă pentru predicția performanței.
email	Informație personală/de identificare; nu trebuie folosită în model.
career_aspiration	Variabilă categorială cu multe valori și categorie Unknown; poate introduce zgomot și c
math_score	Scor individual folosit la calcularea targetului average_score; păstrarea lui ar produce c
history_score	Scor individual folosit la calcularea targetului average_score; păstrarea lui ar produce c
physics_score	Scor individual folosit la calcularea targetului average_score; păstrarea lui ar produce c
chemistry_score	Scor individual folosit la calcularea targetului average_score; păstrarea lui ar produce c
biology_score	Scor individual folosit la calcularea targetului average_score; păstrarea lui ar produce c


0

OUTLIERI IDENTIFICAȚI

0.0%

PROCENT OUTLIERI

Vizualizarea outlierilor pentru weekly_self_study_hours



Alege varianta de One-Hot Encoding pentru preview

Păstrează toate categoriile

6

COLOANE ÎNAINTE

7

COLOANE DUPĂ
ENCODING

2

COLOANE CREATE

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Preprocesarea reduce riscul de modele instabile sau interpretări greșite. Eliminarea identificatorilor protejează confidențialitatea, iar eliminarea scorurilor individuale previne un model artificial de bun.

Recomandare: într-un context educațional real, preprocesarea trebuie documentată riguros pentru ca deciziile bazate pe model să fie transparente și auditabile.

Funcționalitatea 6 - Machine Learning: predicția scorului mediu

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic este construirea unui model care poate estima performanța generală a unui student, exprimată prin `average_score`, pe baza comportamentului educațional și a unor caracteristici disponibile înaintea rezultatului final.

Modelul poate susține identificarea studenților aflați în risc academic și poate ajuta instituția să ia măsuri proactive.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Variabilă / element	Rol în funcționalitate
<code>average_score</code>	Variabila țintă prezisă de modelele de regresie.
<code>weekly_self_study_hours</code>	Predictor numeric principal asociat efortului individual.
<code>absence_days</code>	Predictor numeric asociat implicării și prezenței.
<code>part_time_job</code>	Predictor boolean care poate influența timpul disponibil pentru studiu.
<code>extracurricular_activities</code>	Predictor boolean asociat implicării extracurriculare.
<code>gender</code>	Predictor categorial, inclus opțional prin One-Hot Encoding.
<code>test_size</code>	Parametru pentru împărțirea datelor în set de antrenare și set de test.
<code>n_neighbors, n_estimators</code>	Parametri utilizați pentru KNN Regressor și Random Forest Regressor.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Datele sunt împărțite în X, adică variabile predictor, și y, adică `average_score`. Apoi se aplică `train_test_split` pentru separarea datelor în set de antrenare și set de test.

Aplicația permite alegerea modelului: Linear Regression, KNN Regressor sau Random Forest Regressor.

Pentru KNN, numărul de vecini controlează câte observații apropiate sunt folosite pentru predicție. Pentru Random Forest, numărul de arbori controlează complexitatea ansamblului de arbori decizionali.

Modelele sunt evaluate cu R^2 , RMSE și MAE. R^2 arată proporția variației explicate de model, RMSE penalizează mai puternic erorile mari, iar MAE indică eroarea medie absolută exprimată în puncte de scor.

Aplicația include și regresie multiplă cu `statsmodels`, folosind formula: `average_score ~ weekly_self_study_hours + absence_days + part_time_job + extracurricular_activities + C(gender)`. Coeficienții sunt interpretați prin direcția și mărimea relației dintre fiecare predictor și `average_score`.

d) Prezentarea rezultatelor: capturi de ecran

Pasul 1 - Configurarea modelului de regresie

Observație: target-ul este `average_score`. Variabilele folosite pentru predicție sunt cele rămase după preprocesare: `gender`, `part_time_job`, `absence_days`, `extracurricular_activities` și `weekly_self_study_hours`.

Model de regresie

Linear Regression

Configurare antrenare

Test size

0.20



Aplică One-Hot Encoding
pentru gender



Aplică scaling pentru
predictorii numerici

Antrenează modelul

Pasul 2 - Rezultatele modelului

0.281

R^2

5.56

RMSE

4.48

MAE

1600

RÂNDURI
TRAIN

Configurație folosită:

Model: Linear Regression

Parametri model: Fără parametri suplimentari

Test size: 0.2

Random state: 42

Encoding gender: activat

Scaling: Fără scaling

Variabile folosite: part_time_job, absence_days, extracurricular_activities,
weekly_self_study_hours, gender_female, gender_male

Pasul 3 - Regresie multiplă cu statsmodels

În această secțiune folosim pachetul **statsmodels** pentru construirea unui model de regresie multiplă. Spre deosebire de modelele predictive din scikit-learn, acest model este folosit mai ales pentru interpretarea relației dintre variabile și pentru analizarea coeficienților, valorilor p-value și semnificației statistice.

Obiectiv: analizăm în ce măsură variabilele rămase după preprocesare pot explica scorul mediu al unui student (**average_score**). Variabilele categoricale sunt tratate cu **C(...)**, astfel încât statsmodels să le transforme automat în variabile dummy.

0.266

R-SQUARED

0.265

ADJUSTED R-SQUARED

0.000

MODEL P-VALUE

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Rezultatele modelului trebuie interpretate cu atenție. Un R^2 ridicat indică o capacitate mai bună de explicare, dar nu garantează cauzalitate. Un R^2 scăzut arată că variabilele disponibile nu explică suficient performanța, ceea ce poate însemna că lipsesc factori importanți precum nivelul socio-economic, calitatea predării, timpul real de pregătire sau motivația studentului.

Recomandare: modelul poate fi folosit ca instrument exploratoriu și de suport decizional, nu ca mecanism automat de evaluare a studenților. Instituția ar trebui să combine predicțiile cu interpretare umană și cu date suplimentare înainte de a lua decizii sensibile.

Concluzii generale și recomandări pentru business

Componenta Streamlit a proiectului oferă o interfață completă pentru explorarea și interpretarea datelor educaționale. Aplicația pornește de la înțelegerea dataset-ului, continuă cu feature engineering și analiză exploratorie, apoi pregătește datele pentru machine learning și evaluează modele predictive.

Din perspectivă economică, proiectul poate ajuta o instituție de învățământ să transforme datele despre studenți în indicatori utili pentru decizie. Monitorizarea scorului mediu, a absențelor, a orelor de studiu și a activităților extracurriculare poate sprijini politici educaționale mai bine direcționate.

Recomandarea principală este folosirea aplicației ca instrument de analiză și suport decizional. Rezultatele modelelor trebuie completate cu expertiză pedagogică și cu date suplimentare, deoarece performanța academică este influențată de factori multipli care nu sunt întotdeauna prezenți în dataset.

Pentru dezvoltări viitoare, aplicația poate fi extinsă prin includerea variabilei `career_aspiration` într-un model mai avansat, prin testarea unor metode de validare mai robuste, prin salvarea rezultatelor într-o bază de date și prin adăugarea unor rapoarte automate pentru managementul instituției.

Anexă - formule și indicatori utilizați

Metodă / indicator	Descriere
average_score	Media aritmetică a scorurilor la cele șapte discipline.
IQR	$IQR = Q3 - Q1$; limite outlier = $Q1 - k \cdot IQR$ și $Q3 + k \cdot IQR$.
Z-score	$z = (x - \text{media}) / \text{deviația standard}$.
StandardScaler	$x_{\text{scaled}} = (x - \text{media}) / \text{deviația standard}$.
MinMaxScaler	$x_{\text{scaled}} = (x - \min) / (\max - \min)$.
MAE	Mean Absolute Error = media valorilor absolute ale erorilor.
RMSE	Root Mean Squared Error = rădăcina pătrată a mediei erorilor pătratice.
R ²	Coefficient de determinare; arată proporția variației explicate de model.
Regresie multiplă statsmodels	$\text{average_score} \sim \text{weekly_self_study_hours} + \text{absence_days} + \text{part_time_job} + \text{extracurricular_activities} + C(\text{gender})$.

Programare SAS

SAS este componenta de procesare statistică și raportare analitică a proiectului. În cadrul acestei componente, datele sunt importate, standardizate, transformate și analizate prin proceduri statistice și grafice, astfel încât concluziile să fie validate matematic și utile pentru decizii educaționale și de business.

Acuratețe statistică: rularea de proceduri descriptive, corelații și regresii pentru identificarea relațiilor reale dintre factori precum absențele, orele de studiu și performanța academică.

Data management: curățarea, transformarea și standardizarea datelor brute provenite din fișierul CSV înainte de raportare și vizualizare.

Scalabilitate și raportare: crearea de seturi de date, subseturi, rapoarte, tabele și grafice care pot fi folosite pentru monitorizarea performanței școlare.

Sursa datelor și contextul analizei SAS

Sursa datelor: Platforma Kaggle - Student Scores Dataset:
<https://www.kaggle.com/datasets/markmedhat/student-scores>

Context: setul de date oferă o perspectivă asupra factorilor externi și interni care pot influența succesul academic al elevilor dintr-o instituție de învățământ standard.

Indicatori de performanță: notele obținute de elevi la discipline precum Matematică, Istorie, Fizică, Chimie, Biologie, Engleză și Geografie.

Implicare și pregătire: variabile precum numărul de absențe, orele de studiu individual, participarea la activități extrașcolare și existența unui job part-time.

Variabilele folosite

Variabilă	Descriere
1. Identificare	
id	Identificator unic pentru fiecare student.
first_name	Prenumele studentului.
last_name	Numele de familie al studentului.
email	Adresa de email instituțională a studentului.
2. Comportament & Demografic	
gender	Genul elevului (Ex: male, female).
part_time_job	Indică dacă elevul are un loc de muncă (TRUE/FALSE).
absence_days	Numărul total de zile de absență.
extracurricular_activities	Participarea la activități extrașcolare (TRUE/FALSE).
weekly_self_study_hours	Ore dedicate studiului individual pe săptămână.
3. Aspirații	
career_aspiration	Cariera vizată de student (Ex: Doctor, Lawyer).
4. Performanță (Note 0-100)	
math_score	Scorul obținut la Matematică.
history_score	Scorul obținut la Istorie.

physics_score	Scorul obținut la Fizică.
chemistry_score	Scorul obținut la Chimie.
biology_score	Scorul obținut la Biologie.
english_score	Scorul obținut la Limba Engleză.
geography_score	Scorul obținut la Geografie.

Funcționalitatea SAS 1 - Crearea unui set de date SAS din fișiere externe

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic este încărcarea corectă a datelor educaționale într-un format care poate fi procesat statistic. Fără importul controlat al fișierului CSV, instituția nu poate construi rapoarte valide sau modele de analiză a performanței.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Sunt utilizate toate variabilele inițiale din fișier: date de identificare, variabile demografice, comportament educațional, aspirații profesionale și scoruri pe discipline.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Se folosește instrucțiunea FILENAME pentru localizarea fișierului extern, DATA pentru crearea setului WORK.studenti, LENGTH pentru definirea lungimii variabilelor text și INFILE cu opțiunile FIRSTOBS=2, DSD și TRUNCOVER pentru citirea corectă a CSV-ului.

d) Prezentarea rezultatelor: capturi de ecran

```
FILENAME stud "/home/u64505469/Calugaru.Mircea-Costin/data/student-scores.csv";

DATA WORK.studenti;
  LENGTH
    first_name $ 30
    last_name $ 30
    email $ 50
    gender $ 10
    part_time_job $ 5
    extracurricular $ 5
    career_aspiration $ 30;

  INFILE stud FIRSTOBS=2 DSD TRUNCOVER;

  INPUT
    id
    first_name $
    last_name $
    email $
    gender $
    part_time_job $
    absence_days
    extracurricular $
    weekly_self_study_hours
    career_aspiration $
    math_score
    history_score
    physics_score
    chemistry_score
    biology_score
    english_score
    geography_score;

RUN;

PROC PRINT DATA=WORK.studenti(OBS=10);
```

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Rezultatul permite trecerea de la date brute la date analizabile. Din perspectivă managerială, această etapă garantează că deciziile ulterioare sunt construite pe o bază de date coerentă și verificabilă.

Funcționalitatea SAS 2 - Crearea și folosirea de formate definite de utilizator

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic este transformarea valorilor tehnice în etichete ușor de înțeles de către utilizatori non-tehnici, precum manageri educaționali sau cadre didactice.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Sunt folosite variabilele `gender`, `career_aspiration`, `avg_score` și `absence_days`, deoarece acestea sunt mai ușor de interpretat atunci când valorile sunt grupate sau traduse în etichete descriptive.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Se utilizează PROC FORMAT pentru definirea formatelor `$GENDER_FMT`, `$CAREER_FMT`, `GRADE_FMT` și `ABS_FMT`. Aceste formate sunt apoi aplicate în setul de date prin instrucțiunea FORMAT.

d) Prezentarea rezultatelor: capturi de ecran

```
PROC FORMAT;
  /* Format pentru gen (character) */
  VALUE $GENDER_FMT
    'male'      = 'Masculin'
    'female'    = 'Feminin'
    OTHER      = 'Necunoscut';

  /* Format pentru aspiratia in cariera */
  VALUE $CAREER_FMT
    'Doctor'      = 'Medic'
    'Lawyer'      = 'Avocat'
    'Software Engineer' = 'Inginer Software'
    'Teacher'     = 'Profesor'
    'Artist'      = 'Artist'
    'Government Officer' = 'Functionar Public'
    'Unknown'     = 'Nedefinit';

  /* Format numeric pentru scor mediu -> calificativ */
  VALUE GRADE_FMT
    0  -< 65 = 'Insuficient'
    65 -< 75 = 'Satisfacator'
    75 -< 85 = 'Bine'
    85 -< 92 = 'Foarte Bine'
    92  - HIGH = 'Excelent';

  /* Format pentru absente */
  VALUE ABS_FMT
    0  - 2 = 'Prezenta buna'
    3  - 5 = 'Absente moderate'
    6  - HIGH = 'Absente ridicate';

RUN;

/* Aplicare formate pe setul de date */
DATA WORK.studenti;
  SET WORK.studenti;
  FORMAT gender      $GENDER_FMT.
         career_aspiration $CAREER_FMT.
         absence_days  ABS_FMT.;

RUN;
```

Captură de ecran SAS - Crearea și folosirea de formate definite de utilizator

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Formatele cresc claritatea rapoartelor și reduc riscul de interpretare greșită. Instituția poate comunica mai ușor rezultatele către persoane care nu lucrează direct cu date brute.

Funcționalitatea SAS 3 - Procesare iterativă și condiționată a datelor

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic este construirea unor indicatori sintetici pentru evaluarea rapidă a performanței și a profilului elevului.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Sunt utilizate scorurile la cele șapte discipline, variabilele `part_time_job`, `extracurricular` și `weekly_self_study_hours`.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Se calculează `avg_score` prin `MEAN`, `total_score` prin `SUM` și se folosesc structuri `IF-ELSE` și `SELECT-WHEN` pentru clasificarea elevilor. De asemenea, se simulează acordarea unui bonus printr-o buclă `DO`.

d) Prezentarea rezultatelor: capturi de ecran

```
DATA WORK.studenti_procesati;
    SET WORK.studenti;

    avg_score = MEAN(math_score, history_score, physics_score,
                     chemistry_score, biology_score,
                     english_score, geography_score);

    avg_score = ROUND(avg_score, 0.01);

    total_score = SUM(math_score, history_score, physics_score,
                     chemistry_score, biology_score,
                     english_score, geography_score);

    /* Procesare CONDITIONALA: calificativ */
    IF avg_score >= 92 THEN calificativ = 'Excelent';
    ELSE IF avg_score >= 85 THEN calificativ = 'Foarte Bine';
    ELSE IF avg_score >= 75 THEN calificativ = 'Bine';
    ELSE IF avg_score >= 65 THEN calificativ = 'Satisfacator';
    ELSE calificativ = 'Insuficient';

    /* Procesare conditionala: statut job */
    IF part_time_job = 'TRUE' THEN statut_job = 'Angajat part-time';
    ELSE statut_job = 'Fara job';

    /* SELECT-WHEN (alternativa la IF-ELSE) */
    SELECT (extracurricular);
        WHEN ('True') activ_extracurricular = 'Da';
        WHEN ('False') activ_extracurricular = 'Nu';
        OTHERWISE activ_extracurricular = 'NS/NR';
    END;

    /* Procesare ITERATIVA: adaos bonus scor pentru activitati extra */
    .
```

Captură de ecran SAS - Procesare iterativă și condiționată a datelor

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Indicatorii rezultați permit segmentarea rapidă a elevilor în grupe de performanță, sprijinind decizii precum intervenții remediale, programe de excelență sau monitorizarea elevilor cu risc.

Funcționalitatea SAS 4 - Crearea de subseturi de date

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic este izolarea unor grupuri de interes pentru analiză separată: elevi performanți, studenți, aspirații profesionale specifice sau elevi cu profil educațional bun.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Sunt utilizate variabilele avg_score, gender, career_aspiration, absence_days și weekly_self_study_hours.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Subseturile sunt create cu DATA, SET, WHERE, IF și KEEP. Aceste instrucțiuni selectează doar observațiile și variabilele relevante pentru fiecare analiză.

d) Prezentarea rezultatelor: capturi de ecran

```
/* Subset 1: Studenti cu medie >= 85 */  
DATA WORK.studenti_top;  
    SET WORK.studenti_procesati;  
    WHERE avg_score >= 85;  
RUN;  
  
/* Subset 2: Studente (gen feminin) */  
DATA WORK.studente_feminine;  
    SET WORK.studenti_procesati;  
    IF gender = 'female';  
    KEEP id nume_complet avg_score career_aspiration gender;  
RUN;  
  
/* Subset 3: Viitori medici si avocati */  
DATA WORK.aspiratii_nobile;  
    SET WORK.studenti_procesati;  
    WHERE career_aspiration IN ('Doctor', 'Lawyer');  
    KEEP id nume_complet career_aspiration avg_score math_score biology_score;  
RUN;  
  
/* Subset 4: Fara absente excesive si studiu intens */  
DATA WORK.studenti_model;  
    SET WORK.studenti_procesati;  
    WHERE absence_days <= 3 AND weekly_self_study_hours >= 20;  
RUN;
```

Captură de ecran SAS - Crearea de subseturi de date

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Subseturile permit intervenții diferențiate. De exemplu, elevii cu medii ridicate pot fi incluși în programe de excelență, iar cei cu profil favorabil pot fi analizați ca exemple de bune practici.

Funcționalitatea SAS 5 - Utilizarea de funcții SAS

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic este îmbogățirea dataset-ului cu variabile derivate care facilitează raportarea și interpretarea.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Sunt folosite variabile precum first_name, last_name, email, math_score, avg_score și data curentă a raportării.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Se folosesc funcții precum MAX, MIN, ABS, UPCASE, PROPCASE, SCAN, LENGTH, PUT, YEAR, TODAY și WEEKDAY pentru calcul, transformare de text, conversie și extragere de informații calendaristice.

d) Prezentarea rezultatelor: capturi de ecran

```
DATA WORK.functii_demo;
SET WORK.studenti_procesati;

/* Functii matematice */
scor_max    = MAX(math_score, history_score, physics_score,
                  chemistry_score, biology_score,
                  english_score, geography_score);

scor_min    = MIN(math_score, history_score, physics_score,
                  chemistry_score, biology_score,
                  english_score, geography_score);

deviatia    = ABS(math_score - avg_score);

/* Functii sir de caractere */
prenume_upper = UPCASE(first_name);
prenume_proper = PROPCASE(first_name);
email_domeniu = SCAN(email, 2, '@');
lung_prenume  = LENGTHN(first_name);

/* Functii de conversie */
id_char      = PUT(id, 2.);           /* numeric -> caracter */
scor_char    = PUT(avg_score, 6.2);

/* Functii de data */
an_curent    = YEAR(TODAY());
zi_saptamana = WEEKDAY(TODAY());
```


e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Funcțiile SAS cresc valoarea informațională a datelor. Prin variabile derivate, rapoartele devin mai clare și mai utile pentru monitorizarea periodică a performanței.

Funcționalitatea SAS 6 - Combinarea seturilor de date

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic este integrarea informațiilor din surse diferite pentru obținerea unei imagini mai complete asupra elevilor.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Sunt utilizate seturi separate pe gen și un set de informații suplimentare care conține ranguri sau burse, legate prin identificatorul id.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Combinarea este realizată prin concatenare verticală cu SET, sortare cu PROC SORT, îmbinare cu MERGE pe cheia id și interogări SQL cu PROC SQL, INNER JOIN, CASE WHEN și agregări grupate.

d) Prezentarea rezultatelor: capturi de ecran

```
DATA WORK.masculin;
    SET WORK.studenti_procesati;
    WHERE gender = 'male';
RUN;

DATA WORK.feminin;
    SET WORK.studenti_procesati;
    WHERE gender = 'female';
RUN;

DATA WORK.toti_concatenat;
    SET WORK.masculin WORK.feminin;
RUN;

PROC PRINT DATA=WORK.toti_concatenat (OBS=10);
    VAR id nume_complet gender avg_score;
    TITLE "6A. SET - concatenare verticala (masculin + feminin)";
RUN;
```

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Integrarea datelor permite analiza elevilor nu doar prin note, ci și prin informații suplimentare, cum ar fi bursele sau rangurile. Astfel, deciziile instituției devin mai complete și mai bine fundamentate.

Funcționalitatea SAS 7 - Utilizarea de masive

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic este procesarea eficientă a scorurilor la mai multe discipline fără repetarea manuală a aceluiași calcul.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Sunt utilizate scorurile la Matematică, Istorie, Fizică, Chimie, Biologie, Engleză și Geografie.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Se folosesc ARRAY și bucle DO pentru identificarea scorurilor maxime/minime, numărarea disciplinelor cu scoruri peste 80 sau sub 70 și normalizarea scorurilor de la scala 0-100 la 0-10.

d) Prezentarea rezultatelor: capturi de ecran

```
DATA WORK.masive_demo;
  SET WORK.studenti_procesati;

  /* ARRAY unidimensional: toate scorurile */
  ARRAY scoruri[7] math_score history_score physics_score
                  chemistry_score biology_score
                  english_score geography_score;

  /* Calcule iterative pe masiv */
  scor_max2 = scoruri[1];
  scor_min2 = scoruri[1];
  nr_peste_80 = 0;
  nr_sub_70   = 0;

  DO i = 1 TO DIM(scoruri);
    IF scoruri[i] > scor_max2 THEN scor_max2 = scoruri[i];
    IF scoruri[i] < scor_min2 THEN scor_min2 = scoruri[i];
    IF scoruri[i] > 80 THEN nr_peste_80 + 1;
    IF scoruri[i] < 70 THEN nr_sub_70   + 1;
  END;

  /* ARRAY pentru normalizare scoruri (0-100 -> 0-10) */
  ARRAY scoruri_norm[7]
          math_n hist_n phys_n chem_n bio_n eng_n geo_n;

  DO i = 1 TO DIM(scoruri_norm);
    scoruri_norm[i] = ROUND(scoruri[i] / 10, 0.1);
  END;

  DROP i;
```

Captură de ecran SAS - Utilizarea de masive

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Prin masive, analiza devine mai scalabilă. Instituția poate compara disciplinele rapid și poate identifica materiile unde elevii întâmpină dificultăți.

Funcționalitatea SAS 8 - Utilizarea de proceduri pentru raportare

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic este generarea unor rapoarte clare cu elevi și indicatori relevanți pentru analiză managerială.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Sunt utilizate variabilele id, nume_complet, gender, avg_score, total_score, absence_days, calificativ și career_aspiration.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Se utilizează PROC PRINT pentru afișarea listelor și PROC REPORT pentru rapoarte detaliate cu etichete, formate și coloane definite explicit.

d) Prezentarea rezultatelor: capturi de ecran

```
PROC PRINT DATA=WORK.studenti_procesati NOOBS;
  VAR id nume_complet gender avg_score calificativ career_aspiration;
  WHERE avg_score >= 80;
  LABEL id='Nr. Crt'
        nume_complet='Nume Student'
        gender='Gen'
        avg_score='Medie'
        calificativ='Calificativ'
        career_aspiration='Aspiratie Cariera';
  TITLE "8A. PROC PRINT - Studenti cu medie >= 80";
  FORMAT avg_score 8.2;
RUN;

/* 8B: PROC REPORT */
PROC REPORT DATA=WORK.studenti_procesati NOWD;
  COLUMNS id nume_complet gender avg_score total_score
            absence_days calificativ;
  DEFINE id / DISPLAY 'ID';
  DEFINE nume_complet / DISPLAY 'Nume Complet';
  DEFINE gender / DISPLAY 'Gen';
  DEFINE avg_score / DISPLAY 'Medie' FORMAT=8.2;
  DEFINE total_score / DISPLAY 'Total Scoruri';
  DEFINE absence_days / DISPLAY 'Absente';
  DEFINE calificativ / DISPLAY 'Calificativ';
  TITLE "8B. PROC REPORT - Raport detaliat studenti";
RUN;
```

Captură de ecran SAS - Utilizarea de proceduri pentru raportare

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Rapoartele oferă conducerii o imagine rapidă asupra elevilor cu performanțe peste anumite praguri și pot susține selecția pentru programe speciale sau intervenții educaționale.

Funcționalitatea SAS 9 - Folosirea de proceduri statistice

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic este validarea relațiilor dintre variabile prin metode statistice, nu doar prin observații vizuale.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Sunt folosite variabilele de scor, avg_score, gender, absence_days și weekly_self_study_hours.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Se utilizează PROC MEANS pentru statistici descriptive, PROC UNIVARIATE pentru distribuții, PROC CORR pentru corelații și PROC REG pentru regresia scorului mediu în funcție de absențe și ore de studiu.

d) Prezentarea rezultatelor: capturi de ecran

```
/* 9A: PROC MEANS */
PROC MEANS DATA=WORK.studenti_procesati N MEAN STD MIN MAX MEDIAN;
  VAR math_score history_score physics_score chemistry_score
      biology_score english_score geography_score avg_score;
  TITLE "9A. PROC MEANS - Statistici descriptive scoruri";
RUN;

/* 9B: PROC MEANS pe grupuri */
PROC MEANS DATA=WORK.studenti_procesati N MEAN STD;
  CLASS gender;
  VAR avg_score math_score biology_score;
  TITLE "9B. PROC MEANS - Comparatie medii pe gen";
RUN;

/* 9C: PROC UNIVARIATE */
PROC UNIVARIATE DATA=WORK.studenti_procesati NORMAL PLOT;
  VAR avg_score;
  TITLE "9C. PROC UNIVARIATE - Distributia mediei generale";
RUN;

/* 9D: PROC CORR - corelatii intre discipline */
PROC CORR DATA=WORK.studenti_procesati;
  VAR math_score physics_score chemistry_score biology_score
      history_score english_score geography_score;
  TITLE "9D. PROC CORR - Matricea de corelatii intre discipline";
RUN;

/* 9E: PROC REG - regresie: avg_score ~ absente + ore_studiu */
PROC REG DATA=WORK.studenti_procesati;
  MODEL avg_score = absence_days weekly_self_study_hours / R;
  TITLE "9E. PROC REG - Regresia mediei in functie de absente si ore studiu";
RUN;
```

9E. PROC REG - Regresia mediei in functie de absente si ore studiu

The REG Procedure
Model: MODEL1
Dependent Variable: avg_score

Number of Observations Read	100
Number of Observations Used	100

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	2	870.15179	435.07589	16.99	<.0001
Error	97	2483.86994	25.60691		
Corrected Total	99	3354.02172			

Root MSE	5.06033	R-Square	0.2594
Dependent Mean	80.59260	Adj R-Sq	0.2442
Coeff Var	6.27890		

Parameter Estimates					
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	1	77.35506	1.40665	54.99	<.0001
absence_days	1	-0.26369	0.21065	-1.25	0.2137
weekly_self_study_hours	1	0.23045	0.04562	5.05	<.0001

Rezultatul regresiei SAS - avg_score în funcție de absențe și ore de studiu

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Modelul de regresie arată că variabilele analizate explică aproximativ 26% din variația mediei, iar orele de studiu au un efect semnificativ. Această concluzie susține recomandarea de a investi în programe care cresc calitatea și eficiența studiului individual.

Funcționalitatea SAS 10 - Generarea de grafice

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic este transformarea rezultatelor statistice în vizualizări ușor de interpretat, utile pentru comunicarea deciziilor.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Sunt folosite avg_score, calificativ, weekly_self_study_hours, gender, career_aspiration și scorurile pe discipline.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Se utilizează PROC SGPLOT pentru histogramme, grafice de bare, scatter plot-uri cu regresie, box plot-uri și comparații între scoruri pe discipline.


d) Prezentarea rezultatelor: capturi de ecran

```
/* 10A: Histograma distributia mediei generale */
PROC SGPLOT DATA=WORK.studenti_procesati;
    HISTOGRAM avg_score / BINWIDTH=5 FILLATTRS=(COLOR=CX4E79A7);
    DENSITY avg_score / TYPE=KERNEL LINEATTRS=(COLOR=CXE15759 THICKNESS=2);
    XAXIS LABEL="Medie generala";
    YAXIS LABEL="Frecventa";
    TITLE "10A. Distributia mediei generale a studentilor";
RUN;


/* 10B: Bar chart - distributia pe calificative */
PROC SGPLOT DATA=WORK.studenti_procesati;
    VBAR calificativ / FILLATTRS=(COLOR=CX76B7B2) DATALABEL;
    XAXIS LABEL="Calificativ";
    YAXIS LABEL="Nr. Studenti";
    TITLE "10B. Distributia studentilor pe calificative";
RUN;

/* 10C: Scatter plot - ore studiu vs medie generala, colorat pe gen */
PROC SGPLOT DATA=WORK.studenti_procesati;
    SCATTER X=weekly_self_study_hours Y=avg_score /
        GROUP=gender
        MARKERATTRS=(SIZE=10)
        DATALABEL=initiale;
    REG X=weekly_self_study_hours Y=avg_score /
        GROUP=gender LINEATTRS=(THICKNESS=1.5);
    XAXIS LABEL="Ore studiu individual / sapt.";
    YAXIS LABEL="Medie generala";
    KEYLEGEND / TITLE="Gen";
    TITLE "10C. Relatia ore studiu vs medie, pe gen (cu dreapta de regresie)";
RUN;
```


Captură de ecran SAS - Generarea de grafice




Histogramă - distribuția mediei generale




Bar chart - distribuția studenților pe calificative



Scatter plot - ore studiu vs medie, pe gen



Box plot - media pe aspirații profesionale



Comparație scoruri pe discipline

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Graficele arată distribuția performanței, relația pozitivă dintre studiu și medie și diferențele între aspirații profesionale. Pentru business, aceste vizualizări pot fundamenta programe de mentorat, orientare și suport pe discipline.

Interpretarea economică - componenta SAS

1. Profilul Academic General (Statistici Descriptive & Distribuție)

- Eșantion robust: Analiza a fost rulată pe un număr de 2.000 de elevi, oferind o bază solidă și reprezentativă pentru inferențe statistice.
- Performanța medie (avg_score) a instituției se situează la 80.98 puncte.
- Performanța pe materii: Matematica înregistrează cele mai bune rezultate medii (83.45), în timp ce materiile din zona științelor naturii par să pună cele mai mari probleme (Biologia având cea mai mică medie, de 79.58).
- Distribuția notelor: Graficul de probabilitate (Q-Q plot) și histograma confirmă o distribuție normală a mediilor generale (sub formă de clopot). Cu toate acestea, diagrama Boxplot evidențiază o serie de valori extreme la polul inferior (outliers sub nota 64). Acești elevi reprezintă grupul de risc major, care necesită intervenții educaționale specifice.

2. Impactul Genului asupra Performanței (Testul T)

- Fără diferențe semnificative: Deși, strict matematic, băieții au o medie generală marginal mai mare (81.06) comparativ cu fetele (80.89), testul T independent demonstrează că această diferență nu este reală la nivel de populație.
- Validare statistică: Valoarea-p ($Pr > |t|$) este de 0.5229, mult peste pragul standard de 0.05. Prin urmare, acceptăm ipoteza nulă: nu există o diferență statistic semnificativă între performanța academică a fetelor și cea a băieților. Genul nu este un predictor relevant pentru succesul școlar în această instituție.

3. Relația dintre Efort și Rezultat (Analiza de Regresie)

- Corelație pozitivă clară: Graficul de dispersie arată o relație liniară ascendentă evidentă între numărul de ore dedicate studiului individual (axa X) și media generală obținută (axa Y). Efortul suplimentar se traduce în mod direct și proporțional în rezultate academice superioare.
- Uniformitate: Dreptele de regresie pentru ambele genuri sunt practic paralele și suprapuse. Acest lucru întărește concluzia testului T: regula „mai mult efort aduce note mai bune” se aplică universal și identic, indiferent de genul elevului.

Concluzii finale - Recomandări

Analiza arată o dispersie uriașă și cele mai slabe performanțe la Biologie (unde se află majoritatea valorilor extreme negative), în contrast puternic cu Matematica și Fizica.

Acțiune: Afacerea poate lansa programe de meditații intensive, module interactive de învățare (e-learning) sau workshop-uri practice dedicate exclusiv acestei materii. Astfel, se rezolvă o problemă urgentă a clienților (elevi/părinți), generând o nouă sursă de venit.

Cursuri de eficiență și "Time Management" Deși corelația dintre orele de studiu și nota finală este pozitivă, datele arată și o ineficiență clară: există elevi care studiază 20 de ore și obțin aceleași note cu cei care studiază peste 40 de ore.

Acțiune: Crearea și vânzarea unor cursuri de „Metode de Învățare Eficientă” sau „Managementul Timpului”. Părinții sunt foarte dispuși să investească în soluții care reduc epuizarea copiilor lor și le maximizează rezultatele (calitatea efortului vs. cantitatea lui).

Studenții care aspiră la roluri precum „Medic” sau „Scientist” au medii ridicate și constante, în timp ce aspiranții la „Business Owner” sau „Avocat” (în mod surprinzător) înregistrează medii mult mai scăzute și o variație uriașă.

Acțiune: Dezvoltarea unor programe de mentorat sau orientare în carieră. Pentru cei din grupul „Business Owner”, se pot crea module care leagă utilitatea științelor exacte și a biologiei de succesul antreprenorial, crescând astfel motivația intrinsecă și implicarea lor în procesul educațional standard.